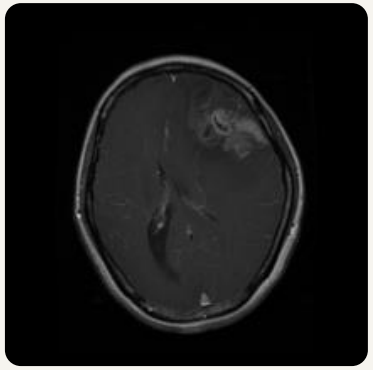
Clasificación de tumores cerebrales en resonancia magnética

PCA, CNN desde cero, ResNet18 preentrenada y aumento de datos sobre el Brain Tumor MRI Dataset

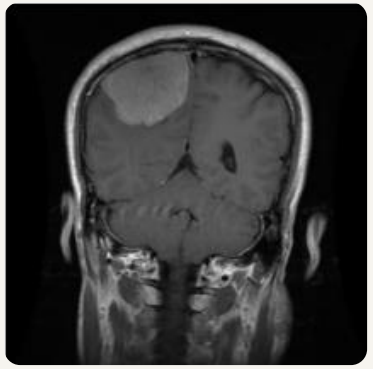
Unai López Lozano de Arnilla

28 de octubre de 2026

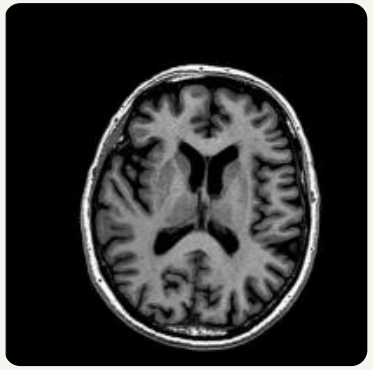
El problema: 4 clases, 3 fuentes y ningún ID de paciente



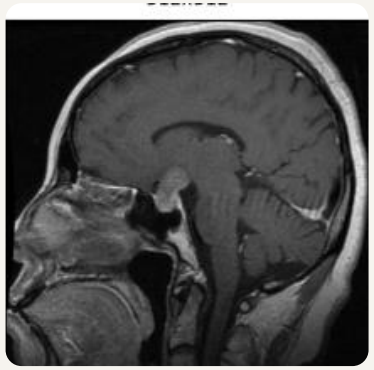
Glioma



Meningioma



Sin tumor



Pituitario

MÉTRICA PRINCIPAL

F1 macro

Mismo peso a cada clase: tras la limpieza dejan de estar balanceadas

7200

imágenes en la partición oficial: 5600 Training / 1600 Testing

3 fuentes

figshare, SARTAJ y Br35H, con resoluciones distintas (→ 224 × 224)

0 IDs

de paciente: no se puede partir por paciente, riesgo de fuga

Antes de entrenar: copias y casi-copias

INICIAL

7200

partición oficial

→

MD5

7013

−187 copias exactas

→

CONFLICTOS

6996

−17: glioma/meningioma casi idénticos

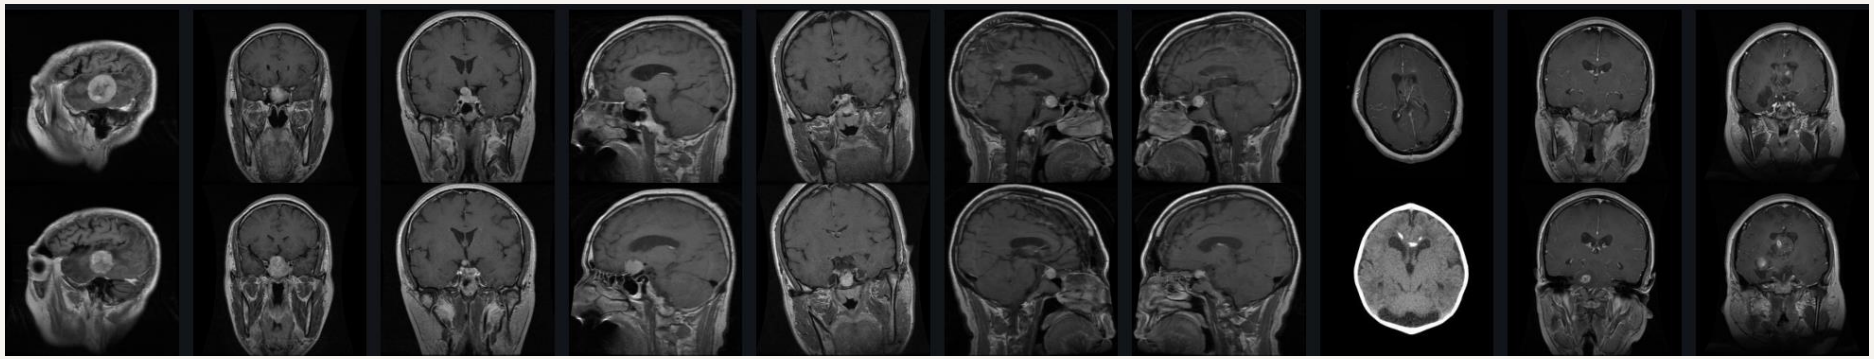
→

pHash = 0

6198

−798; 288 grupos entre Training y Testing

pHash (DCT de baja frecuencia + distancia de Hamming). A d = 6 casi todos los pares son el mismo paciente; a d = 8 surge un grupo de 2743 imágenes → **casi-copia: $d \leq 6$**



Pares aleatorios a distancia 6: misma imagen con otro procesado o cortes contiguos. El octavo es un falso positivo.

Partición sin fugas y protocolo

Training → train / validación

5019 imágenes agrupadas en componentes conexas a d ≤ 6: **3035 grupos**

StratifiedGroupKFold (k = 5): las casi-copias de un grupo caen siempre del mismo lado

`train 3892` `val 1127`

Verificado sobre splits.csv: distancia mínima val–train = 8

Testing → test completo / limpio

Se mantiene el test oficial para poder comparar con otros trabajos

588 de 1179 (50 %) tienen una casi-copia en train + val: se marcan, no se eliminan

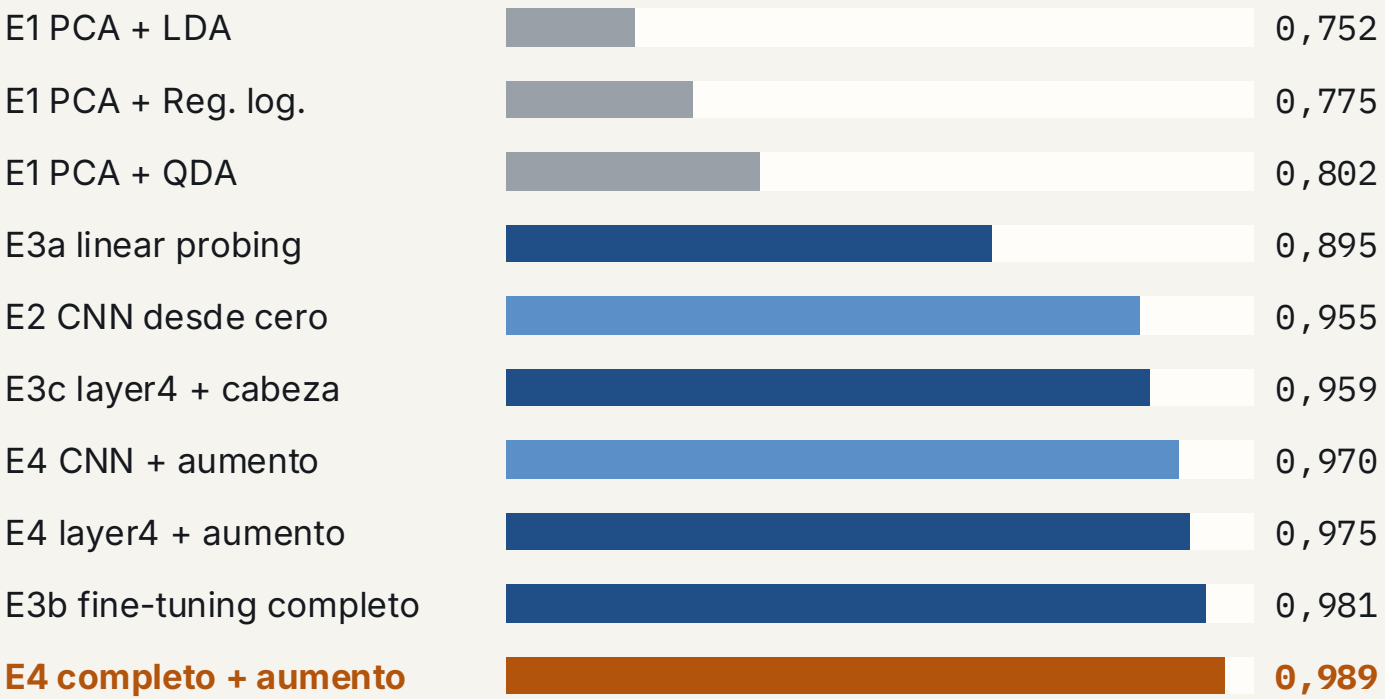
`completo 1179` `limpio 591`

Resultado principal: test completo

PROTOCOLO

- Modelo final = última época
- 3 semillas, se reporta la media
- Test usado una sola vez

E1–E4: F1 macro en validación



+15 pts

CNN desde cero frente a PCA + QDA: aprovechar la estructura espacial de la imagen

0,895 -> 0,981

ResNet18 congelada queda por debajo de la CNN; hay que adaptar toda la red

+0,7 a +1,8

puntos por el aumento de datos, en los 3 modelos y las 3 semillas: ya no memorizan train

Evaluación en test: una caída uniforme

Modelo	Val	Test	Test limpio
E1 PCA + QDA	0,802	0,750	0,633
E3a linear probing	0,895	0,825	0,723
E2 CNN desde cero	0,955	0,907	0,809
E3b fine-tuning completo	0,981	0,927	0,838
E4 completo + aumento	0,989	0,944	0,873

F1 macro, media de 3 semillas. El orden de los modelos se mantiene (tabla completa en la memoria).

−4,5 a −7

puntos de validación a test

−7 a −12

puntos más en el test limpio

¿Inflaban el test las casi-copias?

No explican la caída: la distancia pHash mínima a train es la misma en val (9,8) que en el test limpio (9,9)

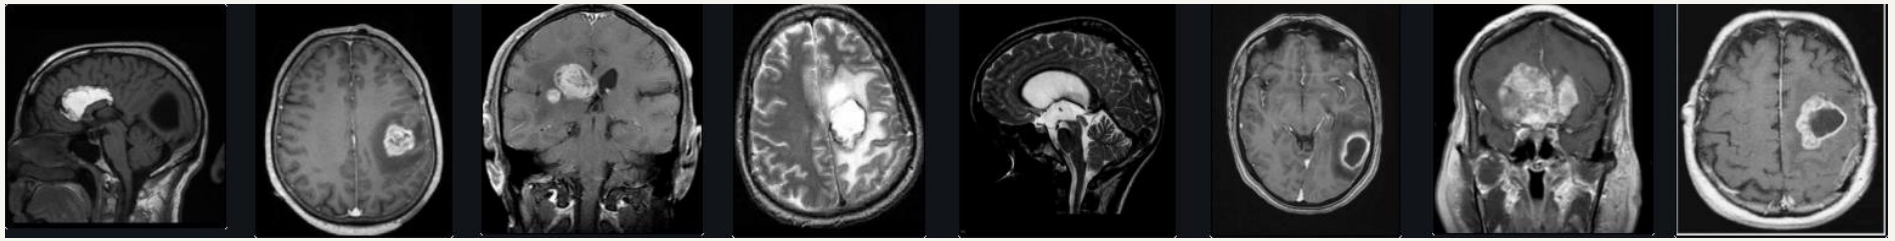
Una caída tan uniforme apunta a los datos de test, no a un modelo concreto.

La caída la explican 62 gliomas de otro formato

Train y val: los 1393 gliomas son 512 × 512. Test: **62 no lo son**.

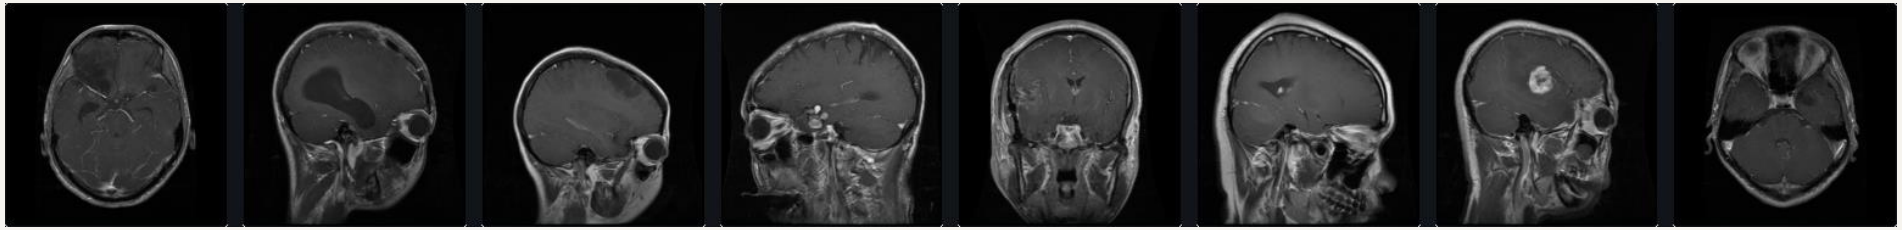
FALLADOS

por ≥ 90 % de las redes, ninguno 512×512



ACERTADOS

por todas las redes, todos 512×512



0,944 -> 0,995

F1 test del mejor modelo sin esos 62 (validación: 0,989)

99,4%

de acierto en el resto del test (1117 imágenes)

51 de 57

errores del mejor modelo están en esos 62 gliomas

Conclusiones

1

Los datos son lo más importante

Sin limpieza ni validación agrupada, la validación estaría inflada; y lo que más pesa en test es un cambio de distribución

2

Las CNN superan a los clásicos

De 0,802 (PCA + QDA) a 0,955 en validación al explotar la estructura espacial

3

Preentrenar, adaptando toda la red

Congelada queda por debajo de la CNN desde cero; con fine-tuning completo es la mejor

4

El aumento de datos siempre suma

Reduce la memorización y es complementario al preentrenamiento

`MEJOR MODELO` ResNet18 completa + aumento