Clasificación de tumores cerebrales en resonancia magnética

Trabajo académico individual - Reconocimiento de Formas y Aprendizaje Automático

Unai López Lozano de Arnilla

Resumen

Se clasifican imágenes de resonancia magnética cerebral en cuatro clases (glioma, meningioma, pituitario y sin tumor) con el *Brain Tumor MRI Dataset* de Kaggle. Antes de entrenar ningún modelo se analizaron los datos, que contenían copias exactas, copias recodificadas, casi-copias entre particiones y pares casi idénticos con etiquetas distintas. Tras limpiarlos y construir una validación agrupada por similitud perceptual (pHash) para evitar fugas, se comparan PCA con clasificadores clásicos (E1), una CNN desde cero (E2), una ResNet18 preentrenada con tres grados de ajuste (E3) y el efecto del aumento de datos (E4). El mejor modelo, ResNet18 con *fine-tuning* completo y aumento de datos, obtiene un F1 macro de 0,989 en validación, 0,944 en test y 0,873 en el test limpio (sin casi-copias de entrenamiento). La caída entre validación y test no se debe a las casi-copias, sino a 62 gliomas de test con un formato que no aparece en entrenamiento: fuera de ellos, el modelo acierta el 99,4-99,5 % del test.

Este documento resume el trabajo; el código, todas las salidas y el resto de figuras están en el cuaderno `rfa_trabajo.ipynb`*, que sigue el mismo orden (EDA, E1-E4, test y análisis de errores).*

1. Problema y dataset

La tarea es una clasificación multiclase de cortes 2D de RM cerebral en `glioma`, `meningioma`, `notumor` y `pituitary`. El dataset trae una partición oficial `Training`/`Testing` de 5600 y 1600 imágenes, perfectamente balanceada. Según su autor, combina tres fuentes públicas: figshare, SARTAJ y Br35H (de esta última procede `notumor`). Las imágenes tienen resoluciones distintas y se redimensionan a 224×224.

El dataset **no incluye identificadores de paciente**. Con imágenes médicas lo correcto sería partir por paciente, para que el modelo no evalúe con cortes de pacientes que vio al entrenar. Al no ser posible, buena parte del trabajo se dedicó a aproximar esa garantía detectando copias y casi-copias.

La métrica principal es el **F1 macro** (media no ponderada del F1 de cada clase), acompañada del acierto. Se eligió porque, tras la limpieza, las clases dejan de estar balanceadas (Sección 2.1) y el F1 macro da el mismo peso a cada clase.

2. Análisis y limpieza de los datos

Un dataset construido juntando varias fuentes suele contener duplicados. Si una imagen, o una casi-copia suya, está a la vez en entrenamiento y en validación o test, el modelo puede acertarla de memoria y los resultados quedan inflados. Por eso este análisis se hizo antes de cualquier experimento. La Tabla 1 resume cada paso.

Hash perceptual. MD5 solo detecta ficheros idénticos byte a byte; la misma imagen recodificada o con otro contraste tiene otro MD5. Para detectarlas se implementó un pHash: la imagen en gris

Paso	Qué se detecta y qué se hace	Imágenes
Inicial	Partición oficial (5600 `Training` + 1600 `Testing`)	7200
MD5	340 imágenes con copia idéntica en 153 grupos, ninguno entre particiones ni entre clases. Se conserva una por grupo (-187).	7013
Conflictos	12 pares glioma/meningioma a distancia pHash ≤ 2. No se puede saber qué etiqueta es la buena: se eliminan las 17 imágenes.	6996
pHash $= 0$	491 grupos de hash idéntico, 288 de ellos entre `Training` y `Testing`. Se conserva una por grupo, con prioridad a `Training` (-798).	6198

Tabla 1: Pasos de limpieza y tamaño del dataset tras cada uno.

se reduce a 32×32, se le aplica la DCT 2D y se toman los 8×8 coeficientes de baja frecuencia sin el término DC (63 valores); cada bit indica si el coeficiente supera la mediana. La similitud se mide con la distancia de Hamming entre hashes (0 = idénticas).

Elección del umbral de casi-copia. Se estudió cómo crecen los grupos de imágenes (componentes conexas del grafo de pares a distancia $\leq d$) y se revisaron visualmente pares a $d = 0, 2, 4, 6$. Incluso a $d = 4$ y $d = 6$ muchos pares son claramente el mismo paciente (Figura 1); a $d = 8$, en cambio, aparece una componente de 2743 imágenes que ya no tiene sentido como grupo de copias (a $d = 6$ el grupo mayor tiene 181). Se fijó $d \leq 6$ como criterio de casi-copia, asumiendo algún falso positivo como el octavo par de la figura.

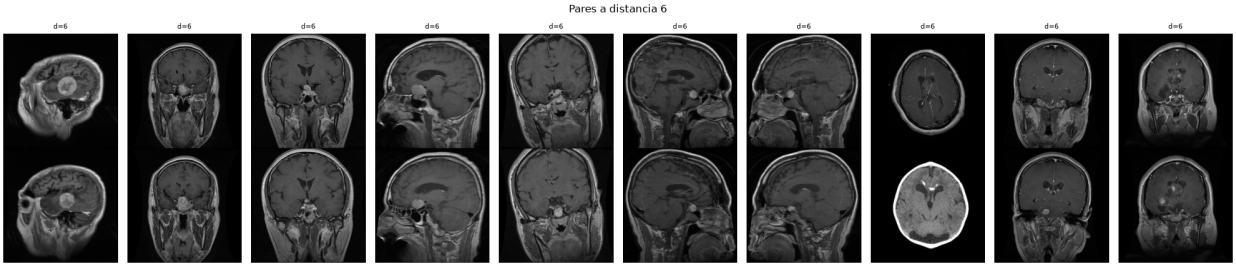


Figura 1: Pares aleatorios a distancia pHash 6. La mayoría son la misma imagen con otro procesado o cortes contiguos del mismo paciente; el octavo es un falso positivo.

2.1. Partición en entrenamiento, validación y test

Se mantiene la partición oficial: `Testing` es el test y `Training` se divide en entrenamiento y validación. Se descartó repartir todo el dataset agrupando por pHash, que habría eliminado también la fuga hacia test, porque el test dejaría de ser comparable con otros trabajos sobre este dataset.

Para dividir `Training` sin fugas, sus imágenes se agrupan en componentes conexas a $d \leq 6$ (3035 grupos; 832 con más de una imagen) y se toma un *fold* de `StratifiedGroupKFold` ($k = 5$) como validación, de forma que las casi-copias de un grupo caen siempre del mismo lado. Una celda final relee `splits.csv` y verifica de forma independiente que no quedan copias, que no hay pares contradictorios y que la distancia mínima entre validación y entrenamiento es 8.

Casi-copias en test. Al mantener la partición oficial, el test sí puede tener casi-copias en entrenamiento: **588 de las 1179 imágenes de test (50 %) tienen una a $d \leq 6$ en train+val**. Se marcan en `splits.csv` y el test se evalúa de dos formas: el **test completo** y el **test limpio**, sin esas imágenes (591), para medir cuánto inflan el resultado.

Clase	Train	Val	Test	Test limpio
glioma	1003 (25,8 %)	390 (34,6 %)	376 (31,9 %)	213
meningioma	1048 (26,9 %)	319 (28,3 %)	292 (24,8 %)	158
notumor	742 (19,1 %)	168 (14,9 %)	113 (9,6 %)	27
pituitary	1099 (28,2 %)	250 (22,2 %)	398 (33,8 %)	193
Total	3892	1127	1179	591

Tabla 2: Partición final. La limpieza desbalancea las clases (`notumor` era la que más duplicados tenía) y la estratificación en validación es aproximada porque los grupos no se pueden partir.

3. Protocolo experimental

- **Entrada.** E1 y la CNN desde cero usan la imagen en gris a 224×224 con valores en $[0, 1]$. La ResNet18 usa la transformación de `timm`: RGB (canal gris replicado), *resize* a 235, recorte central a 224 y normalización de ImageNet.
- **Entrenamiento de las redes.** Entropía cruzada, AdamW ($\text{lr} = 10^{-3}$), planificador coseno de 10^{-3} a 0 en **60 épocas** y *batch* de 32.
- **Modelo final = última época,** no la mejor en validación: elegir la mejor época es seleccionar con validación y su F1 sobrestima el rendimiento real.
- **3 semillas por configuración,** reportando la media, para distinguir mejoras reales de la variabilidad de la inicialización y del orden de los *batches*.
- **El test se usa una sola vez,** con todos los modelos ya fijados.

4. E1: PCA y clasificadores clásicos

Cada imagen se aplana en un vector de 50 176 píxeles y se proyecta con PCA ajustado en train. La varianza está muy repartida: 50 componentes explican el 61 %, hacen falta unas 500 para el 90 % y con 1500 se llega al 97,6 %, muy lejos de lo que ocurre con MNIST. Por eso K se trata como un hiperparámetro y se busca en rejilla junto con la regularización de cada modelo, seleccionando por F1 en validación (Tabla 3).

Modelo	K	Hiperparámetro	Acierto val	F1 val
LDA	300	shrinkage = 0,5	0,751	0,752
Regresión logística	300	$C = 0{,}003$	0,777	0,775
QDA	500	reg_param = 0,9	0,789	**0,802**

Tabla 3: Mejor configuración de cada clasificador clásico sobre PCA.

QDA es el mejor, por poco, y necesita una regularización muy fuerte de las covarianzas. La clase más difícil es `meningioma` y la más fácil `pituitary`, coherente con que los tumores pituitarios aparecen en una localización muy concreta. Estos modelos tratan cada píxel como una variable independiente de su posición y no aprovechan la estructura espacial de la imagen: ese es el hueco que deben cubrir las CNN.

5. E2: CNN desde cero

La red tiene 5 bloques *Conv* 3×3 - *BatchNorm* - *ReLU* - *MaxPool* 2×2; cada bloque duplica los canales (48 a 768) y reduce a la mitad la resolución (224 a 7). La cabeza aplica *global average pooling*, Dropout 0,3 y una capa lineal a 4 clases, con **3,5 M parámetros** en total.

La CNN obtiene un **F1 macro en validación de 0,955** (semillas: 0,959 / 0,956 / 0,951), unos 15 puntos por encima de la mejor línea base, una diferencia muy superior a la variabilidad entre

semillas. Durante las primeras ∼30 épocas la validación oscila de forma errática aunque la pérdida de train baje de forma suave (Figura 2, azul); se probaron otros planificadores, *warmup* y otros tamaños de *batch* sin que desapareciera, y se estabiliza cuando el lr del coseno baja. Al final la red **memoriza el conjunto de entrenamiento** (100 % de acierto, pérdida $\sim 10^{-3}$) mientras la pérdida de validación se estanca en ∼0,15.

6. E3: ResNet18 preentrenada

Se parte de una ResNet18 de `timm` preentrenada en ImageNet y se comparan tres grados de adaptación con el mismo entrenamiento que E2.

Variante	Qué se entrena	Parámetros entrenables	F1 val
E3a *linear probing*	solo la capa final	2052	0,895
E3c *layer4* + cabeza	último bloque residual y capa final	8,4 M (75 %)	0,959
E3b *fine-tuning* completo	toda la red	11,2 M	**0,981**
E2 (CNN desde cero)		*3,5 M*	*0,955*

Tabla 4: Variantes de ajuste de la ResNet18 (media de 3 semillas).

- **E3a**: el acierto en train no pasa del ∼90 % y las curvas de train y val van superpuestas. Las características de ImageNet, tal cual, no separan bien los tumores con una frontera lineal y quedan por debajo de la CNN desde cero.
- **E3c** entrena el 75 % de los parámetros pero queda 2 puntos por debajo del ajuste completo y apenas por encima de E2. Las primeras capas también necesitan adaptarse: los detectores de bajo nivel aprendidos con fotografías en color no son los más adecuados para resonancias en escala de grises.
- **E3b** es la mejor configuración hasta este punto, 2,6 puntos por encima de E2. También memoriza train (pérdida $\sim 10^{-5}$), pero la pérdida de val se queda en ∼0,06: partiendo de mejores pesos, generaliza mejor.

El preentrenamiento es útil como inicialización, no como extractor de características fijo. Todas las variantes que entrenan capas convolucionales llegan al 100 % en train, lo que motiva el aumento de datos.

7. E4: aumento de datos

Se aplica un aumento suave, pensado para generar variantes plausibles de una resonancia: rotación horizontal, afinidad aleatoria (rotación ±10°, traslación ±5 %, escala 0,9-1,1) y variación de brillo y contraste de ±20 %. Solo se aplica a train, y cada modelo mantiene la arquitectura y los hiperparámetros de su experimento original para aislar el efecto del aumento. No se aplica a E3a, cuyo límite es la representación y no la memorización.

Modelo	Sin aumento	Con aumento	Mejora por semilla
CNN desde cero	0,955	0,970	+0,011 a +0,018
ResNet18 *layer4* + cabeza	0,959	0,975	+0,013 a +0,017
ResNet18 completo	0,981	**0,989**	+0,007 a +0,009

Tabla 5: Efecto del aumento de datos en el F1 macro de validación.

El aumento mejora los tres modelos **con las tres semillas**, y la mejora es mayor que la variabilidad entre semillas. La Figura 2 muestra el mecanismo: la pérdida de train de la CNN se queda en ∼0,05 (98 % de acierto) en lugar de caer a 10^{-3}, es decir, la red ya no puede memorizar

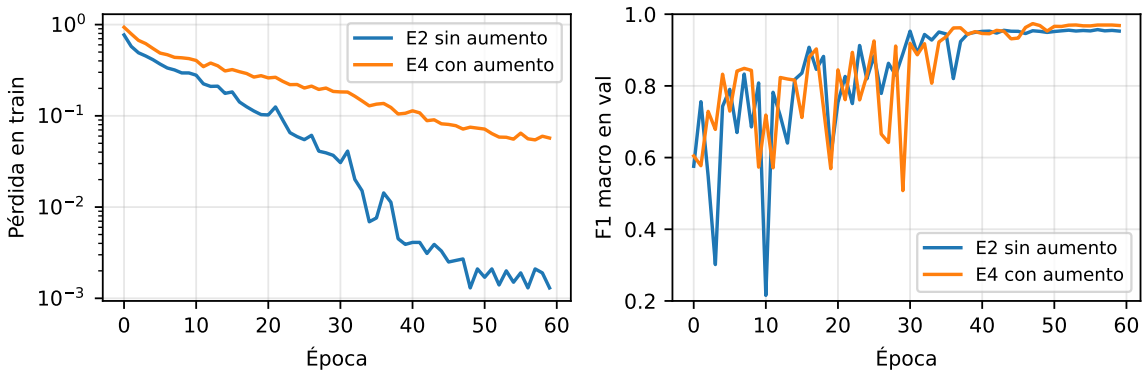


Figura 2: CNN desde cero sin y con aumento (misma semilla). Con aumento, la pérdida de train ya no cae a valores casi nulos y el F1 de validación termina más alto.

las imágenes y a cambio generaliza mejor. Con aumento, la CNN desde cero supera a la ResNet18 *layer4* sin aumento: con pocos datos, regularizar bien puede pesar tanto como partir de pesos preentrenados. Preentrenamiento y aumento son complementarios, y la mejor configuración combina ambos.

8. Evaluación final en test

Modelo	F1 val	F1 test	F1 test limpio	Caída
E1 LDA (K=300)	0,752	0,676	0,565	0,110
E1 Reg. logística (K=300)	0,775	0,706	0,589	0,117
E1 QDA (K=500)	0,802	0,750	0,633	0,117
E3a *linear probing*	0,895	0,825	0,723	0,103
E2 CNN	0,955	0,907	0,809	0,098
E3c *layer4*	0,959	0,911	0,814	0,097
E4 CNN + aumento	0,970	0,918	0,827	0,091
E3b completo	0,981	0,927	0,838	0,089
E4 *layer4* + aumento	0,975	0,934	0,852	0,083
E4 completo + aumento	**0,989**	**0,944**	**0,873**	**0,072**

Tabla 6: Resultados finales (media de 3 semillas; E1 se entrena una sola vez). La última columna es la diferencia de F1 entre el test completo y el limpio.

El mejor modelo en test es el mismo que en validación, y **el orden de los modelos se mantiene** salvo entre E3b y E4 *layer4* + aumento, que ya estaban casi empatados en validación (Tabla 6 y Figura 3). Las conclusiones de E3 y E4 se confirman en test. Sin embargo, **todos los modelos pierden unos 5 puntos entre validación y test, y unos 10 más en el test limpio**. Una caída tan uniforme apunta a los datos de test, no a un modelo concreto.

9. Análisis de la caída en test

Este análisis es posterior a la ejecución del test y no se ha utilizado para modificar ni mejorar ningun modelo.

Las casi-copias no explican la caída. La interpretación inmediata sería que las casi-copias inflaban el test completo. Pero la distancia pHash mínima a entrenamiento es prácticamente la

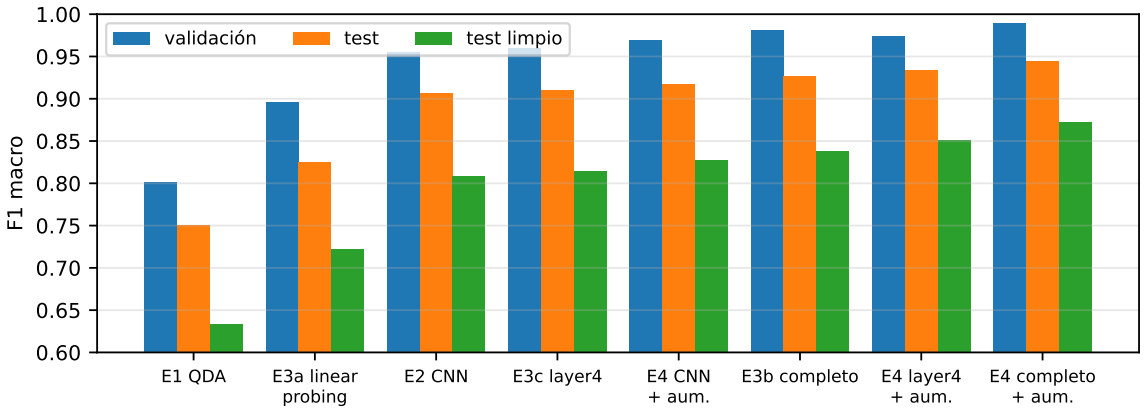


Figura 3: F1 macro en validación, test y test limpio, ordenado por F1 en validación.

misma para validación que para el test limpio (media 9,8 frente a 9,9; mínimo 8 en ambos): el test limpio no está más lejos de train que la validación y, aun así, el F1 baja de 0,99 a 0,87.

La explica un grupo de 62 gliomas. En train y val **todos los gliomas (1393) son de** 512×512; en test hay **62 que no lo son**, y los 62 caen en el test limpio porque no se parecen a nada de entrenamiento. De ellos, 60 los falla la mayoría de las redes, frente a solo 5 de los 151 gliomas de 512×512 del test limpio (Figura 4). Las cuatro redes principales aciertan entre el 6,5 % (E3b) y el 16,7 % (E4 completo + aumento) de ellos. El mejor modelo los confunde sobre todo con `meningioma` y `notumor` (Figura 5); estos 62 gliomas acumulan 51-53 de sus 57-59 errores según la semilla, y **en el resto del test (1117 imágenes) acierta el 99,4-99,5 %**.

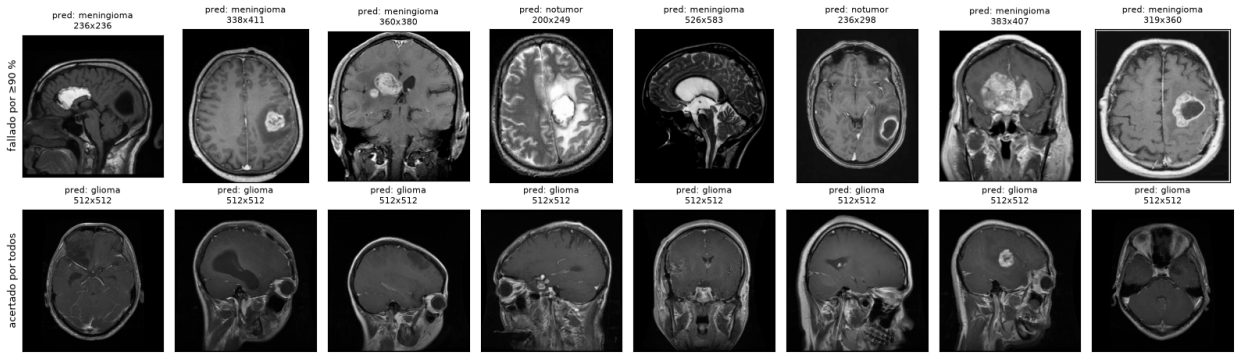


Figura 4: Gliomas del test limpio. Sobre cada imagen, la clase más votada y la resolución original.

Sin esos 62 gliomas, el test coincide con validación. La Tabla 7 repite la evaluación quitando los 62 gliomas. El criterio de exclusión se fijó después de ver el test, pero se define sobre los datos (clase y tamaño de la imagen) y no sobre los errores de los modelos, lo que sería circular. La última columna (F1 sin los 62 menos F1 limpio sin los 62) mide solo el efecto de tener una casi-copia en train/val. Quitar los 62 gliomas sube el F1 de test entre 4,6 y 6,1 puntos en todos los modelos, y el mejor pasa de 0,944 a 0,995, frente a 0,989 en validación. El efecto de las casi-copias es pequeño en las redes (de 0,03 a 2,6 puntos; prácticamente nulo en el mejor modelo) y mayor en E1 (5-7 puntos), lo esperable en modelos que comparan píxeles directamente. Es coherente con que la distancia pHash del test limpio sea igual que la de validación: **la validación agrupada por pHash fue una estimación fiable del rendimiento en la parte del test que sigue la distribución de entrenamiento**.

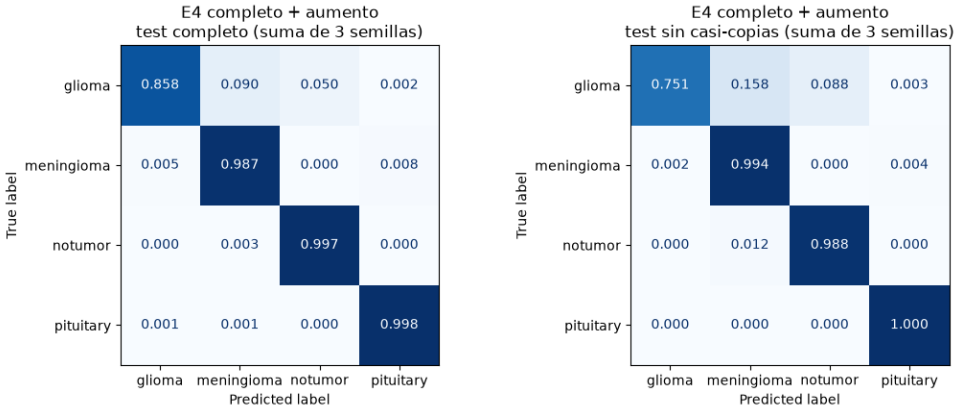


Figura 5: Matriz de confusión normalizada por filas del mejor modelo (suma de 3 semillas) en el test completo y en el test limpio. Prácticamente todo el error está en la fila `glioma`.

Modelo	F1 test	F1 test sin 62	F1 limpio sin 62	Efecto casi-copias
E1 LDA (K=300)	0,6756	0,7218	0,6711	0,0507
E1 Reg. logística (K=300)	0,7061	0,7527	0,6838	0,0690
E1 QDA (K=500)	0,7499	0,8090	0,7592	0,0498
E3a *linear probing*	0,8250	0,8821	0,8566	0,0255
E2 CNN	0,9068	0,9668	0,9499	0,0169
E3c *layer4*	0,9105	0,9697	0,9543	0,0154
E4 CNN + aumento	0,9177	0,9759	0,9654	0,0104
E3b completo	0,9268	0,9882	0,9848	0,0034
E4 *layer4* + aumento	0,9340	0,9874	0,9802	0,0072
E4 completo + aumento	**0,9442**	**0,9948**	**0,9945**	**0,0003**

Tabla 7: F1 macro en test con y sin los 62 gliomas de formato distinto (media de 3 semillas; E1 se entrena una sola vez). Se dan 4 decimales porque algunas diferencias son muy pequeñas.

¿Qué son esos 62 gliomas? Hay dos explicaciones compatibles con los datos, que este trabajo no puede distinguir sin la revisión de un especialista:

1. **Cambio de distribución y aprendizaje por atajo.** Los modelos solo han visto gliomas de 512×512 de una única fuente y pueden haber aprendido rasgos de esa fuente (encuadre, contraste, tipo de secuencia) además del tumor. Lo apoya la Figura 4: varios de los gliomas fallados muestran lesiones bien visibles, mientras que algunos de los acertados apenas muestran el tumor.
2. **Etiquetas erróneas en el test.** El autor del dataset indica que los gliomas de SARTAJ estaban mal clasificados y los sustituyó por los de figshare (que son de 512×512). Si algunos de estos 62 son restos de SARTAJ, parte de los "errores" serían aciertos.

En ambos casos la conclusión práctica es la misma: lo que más condiciona el resultado en test no son las fugas ni el modelo, sino un subconjunto de test que no sigue la distribución de entrenamiento.

10. Conclusiones

1. **Los datos son lo más importante.** Sin la limpieza y la validación agrupada por pHash, la validación habría estado inflada por fugas. Aun así, lo que más condiciona el resultado final es un cambio de distribución en test que ninguna técnica de modelado corrige.
2. **Viendo los resultados, habría sido mejor no respetar la partición oficial.** Mantenerla dejó en test casi-copias de entrenamiento en la mitad de las imágenes y los 62 gliomas con un formato que no aparece en entrenamiento. Unir las 6198 imágenes y repartirlas en entrenamiento, validación y test con la misma agrupación por pHash habría dado un test sin fugas y con una

distribución comparable a la de entrenamiento. A cambio, el test no habría revelado el cambio de distribución, que en un uso real sí aparecería.

3. **Las CNN superan claramente a los métodos clásicos**: de 0,802 (PCA + QDA) a 0,955 en validación con una CNN sencilla que explota la estructura espacial de la imagen.
4. **El preentrenamiento ayuda, pero hay que adaptar toda la red**: sin adaptar queda por debajo de la CNN desde cero; con *fine-tuning* completo da los mejores resultados.
5. **El aumento de datos mejora todos los modelos** a los que se aplica, al reducir la memorización, y es complementario al preentrenamiento.
6. **Mejor modelo: ResNet18 con *fine-tuning* completo y aumento de datos**, con F1 macro de 0,989 en validación y 0,944 en test, y un 99,4-99,5 % de acierto en todo el test salvo los 62 gliomas de formato distinto.

Limitaciones. La agrupación por pHash solo aproxima una partición por paciente. Se usa un único *fold* de validación, y los hiperparámetros se eligieron con él, así que sus cifras son algo optimistas. La CNN desde cero y la ResNet18 reciben entradas ligeramente distintas (imagen completa en gris frente a recorte central en RGB normalizado). El test limpio solo tiene 27 imágenes `notumor`, por lo que su F1 macro es ruidoso: en el mejor modelo, la precisión en esa clase baja a 0,565 por unos pocos gliomas mal clasificados. Por último, la limpieza eliminó del test las imágenes con copia idéntica en `Training`, así que los resultados no son directamente comparables con trabajos que usan las 1600 imágenes originales.